Análise e otimização de viagens NYC Yellow Taxi com Spark

Frederico Mestre (77940)
Tiago Pinho (77970)
p177873@campus.fct.unl.pt
p213933@campus.fct.unl.pt

RESUMO

Analisámos 24 meses de viagens NYC Yellow Taxi, de 2023 e 2024, num cluster Spark em Docker. Implementámos limpeza, análise temporal, estatísticas por zona, deteção de tarifas anómalas e análise de rotas. O estudo compara cache, estratégias de junção, cálculo por janela ou agregação e Adaptive Query Execution (AQE). A cache reduziu a mediana da pipeline de 101,27 para 76,86 s. AQE teve o maior impacto entre as alternativas testadas; reduzir as partições iniciais de shuffle deu diferenças pequenas. Três workers tiveram a menor mediana neste PC, e passar para seis não trouxe um ganho claro.

KEYWORDS

PySpark, NYC Yellow Taxi, profiling, shuffle, Docker

1 INTRODUÇÃO

Usámos os ficheiros mensais Yellow Taxi de 2023 e 2024, publicados em Parquet pela NYC TLC, e a tabela de zonas [2]. São 79 479 946 viagens antes da limpeza e 70 353 039 depois dela. Trabalhar com dois anos permite observar a passagem de dezembro para janeiro nas janelas temporais, mantendo um volume que conseguimos medir várias vezes no mesmo computador.

Além de M1–M3, escolhemos O1 e O2 [1]. O1 permite comparar uma janela sobre as viagens com uma agregação seguida de junção. O2 combina agregações mensais, janelas e duas junções à tabela de zonas. Assim, conseguimos estudar redistribuição de dados e reutilização de resultados, em vez de apenas comparar tempos finais. O objetivo foi perceber que escolhas compensam neste conjunto de dados e neste ambiente, sem assumir que uma opção é sempre melhor.

2 PIPELINE

Usámos a API de DataFrames e funções nativas do Spark. Ficámos próximos dos comandos trabalhados nas Labs e mantivemos os cálculos em `projeto1.py`; os notebooks importam essas funções para os conferir. Não há UDF Python no tratamento das viagens.

2.1 Leitura e limpeza (M1)

O schema define os nomes e tipos das colunas, não as partições. Selecionamos oito colunas e lemos cada mês separadamente, porque a mesma coluna pode ter tipos físicos diferentes entre ficheiros. Com `try_cast`, convertemos para tipos comuns; valores que não podem ser convertidos ficam nulos e entram nas contagens de M1. Depois, `unionByName` junta as linhas dos meses alinhando as colunas pelo nome, sem fazer uma junção por chave. Antes de filtrar, marcamos nulos/NaN, tarifa ou distância não positivas, passageiros fora de 1–6, chegada anterior ou igual à partida e identificadores de zona fora de 1–263. Acrescentámos um critério separado para pickups fora do ano do ficheiro.

Tabela 1: M1 a 100%: problemas por ano. Os critérios sobrepõem-se.

Critério/contagem	2023	2024
Entrada	38 310 226	41 169 720
Nulos ou NaN	1 309 356	4 091 232
Tarifa	394 503	748 284
Distância	773 457	776 305
Passageiros	583 414	401 638
Ordem dos timestamps	15 569	13 510
Zona	633 591	425 660
Ano do pickup	104	56
Removidas, sem duplicar	3 231 939	5 894 968
Viagens válidas	35 078 287	35 274 752

Uma viagem pode falhar várias regras: as contagens por critério não se somam para obter o total removido. A Tabela 1 apresenta os valores de M1. Guardámos a distância original em milhas e criámos uma coluna em km, multiplicando por 1,609344. As tarifas continuam em USD. O fuso da sessão é UTC para tratar as datas sem fuso da origem de forma independente do fuso do PC.

2.2 Análises obrigatórias (M2 e M3)

M2 junta o borough de partida e agrega por borough, dia da semana e hora: conta viagens e calcula tarifa, duração em minutos e distância médias. Escreve Parquet particionado por borough. M3 agrega por zona, ano e mês, calcula médias e desvios-padrão amostrais e completa a grelha de 263 zonas por 24 meses, com zero viagens nos meses vazios. O ranking usa `dense_rank`, preservando empates. A quota móvel usa o mês atual e os dois anteriores. A referência da anomalia usa os três meses anteriores, sem incluir o mês que estamos a testar; sem histórico completo, a classificação fica nula.

2.3 Tarifas e rotas (O1 e O2)

O1 calcula a média e o desvio-padrão da tarifa por km em cada grupo (zona de partida, hora). Sinaliza valores superiores a $\mu + 3\sigma$ e compara taxas por borough, pagamento e dia útil/fim de semana. Em O2 contamos viagens por rota e mês, juntamos os nomes das duas zonas e calculamos a quota nas partidas da origem. O top-20 de cada borough usa o total do período, com desempate pelos IDs. Definimos inversão por ano como sinais opostos de $(s_{mar} - s_{jan})$ e $(s_{set} - s_{jul})$; meses sem viagens da rota entram com quota zero. Estas regras temporais são convenções do grupo.

Escolhemos O1 para estudar o custo de organizar milhões de viagens por zona/hora, comparando janelas com estatísticas agregadas

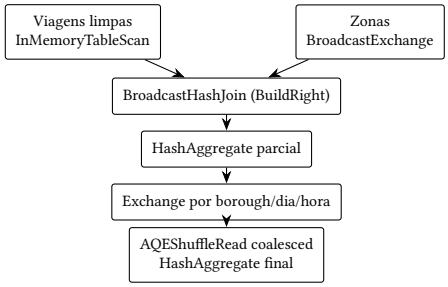


Figura 1: Plano simplificado de M2 com broadcast e AQE. A junção evita redistribuir as viagens por zona, mas a agregação ainda exige shuffle. Origem: plano final de M2 após `collect()`, numa inspeção separada; não é o plano final da escrita da pipeline inteira.

e broadcast. O2 permite estudar a redistribuição por rota e as duas junções às zonas. Um resultado mensal pequeno não implica pouco trabalho: a agregação inicial continua a percorrer as viagens.

3 PROFILING E BASELINE

3.1 Ambiente e método

As medições correram num PC com Intel Core Ultra 9 275HX, 24 cores lógicos e cerca de 31,4 GiB de RAM, com Windows 11 e Docker Desktop. O Docker dispunha de cerca de 15,3 GiB. Usámos Spark 4.2.0 e Python 3.10.12. A configuração principal tem três workers, cada um com dois cores e 2 GiB anunciados ao Spark, e 1536 MiB por executor. São seis slots Spark no mesmo PC; não são três máquinas independentes nem seis cores físicos reservados por quotas Docker. Escolhemos o cluster Docker por seguir as Labs e satisfazer o mínimo de cluster pedido no enunciado. Docker também usa os cores do PC; a alternativa seria `local[*]`, sem workers distribuídos por contentores. Não testámos se Docker é mais rápido que esse modo.

Cada configuração teve três corridas, em aplicações Spark novas e pastas de saída diferentes. Apresentamos a mediana e conservamos os tempos individuais nos notebooks. O tempo global vai da leitura até à última escrita, incluindo preencher a cache e guardar os CSV. Exclui o arranque do Spark e a recolha/exportação das métricas. Não é a soma dos tempos parciais. Usámos o profiler da Lab 3 [3], que agrega métricas dos stages do bloco. Os tempos acumulados dos executors não são tempos de parede, e os bytes de entrada podem incluir leituras da cache, não apenas I/O físico.

Mantivemos os mesmos 24 ficheiros e alterámos uma opção de cada vez. Nos testes principais usamos 200 partições iniciais de shuffle, AQE ligado e broadcast das zonas. A opção que força merge só afeta as zonas; O1 por groupBy continua a usar broadcast das estatísticas. O README inclui os comandos `spark-submit`, versões e configurações; os resultados pequenos e os planos estão no repositório.

3.2 Referência inicial e verificações

A baseline completa é a execução sem cache, já com AQE, broadcast das zonas e O1 por groupBy. Os tempos foram 101,269, 103,528 e 100,620 s: mediana 101,269 s. As medianas de shuffle lido/escrito foram 129,9/113,2 MiB e o número de tarefas foi 4461. Não registámos spill de execução nesta referência. Isto não demonstra, por si só, que não havia custos de memória ou leitura repetida.

As viagens limpas alimentam vários módulos, o que motivou o teste de cache. Depois, usámos a configuração com cache como referência comum para O1, joins, AQE e partições. A implementação inicial já continha várias destas escolhas: os testes com alternativas servem para as avaliar e justificar a sua manutenção. Não representam uma sequência de melhorias acumuladas sobre versões diferentes. Os planos guardados foram inspecionados depois das medições e ajudam a explicar as diferenças; não foram recolhidos como planos finais de todas as escritas medidas.

Validámos M1–O2 a 10% e a 100%, incluindo contagens, exemplos diretos, chaves, quotas, rankings e escrita/leitura. Nas comparações de desempenho conferimos as sete tabelas de saída por chaves. Contagens e valores discretos têm de coincidir; floats não arredondados usam tolerância absoluta 10^{-9} e relativa 10^{-12}. Os testes de arredondamento levaram a usar decimal na tarifa média de M2/M3 e segundos em decimal na duração média de M2. Estas foram correções de estabilidade, não otimizações de tempo.

4 ESTUDO DAS OTIMIZAÇÕES

A Tabela 2 resume o efeito de cada escolha no tempo global da pipeline, mantendo as restantes opções constantes. A Figura 2 compara visualmente esses tempos. Organizamos cada teste em problema observado, hipótese, alteração isolada e resultado. Esta comparação por ablação desliga uma opção da referência; não soma ganhos nem pressupõe que todos os mecanismos já estivessem errados na implementação inicial.

4.1 Reutilização das viagens limpas

A hipótese foi que guardar as viagens limpas evitaria repetir a leitura e a limpeza nos módulos seguintes. Mantivemos as outras opções e alterámos apenas a cache. Os tempos com cache foram 74,981, 76,861 e 79,109 s. A mediana desceu 24,1%, contando também o custo de preencher a cache. As saídas coincidiram com a referência. Por isso mantivemos cache no DataFrame limpo, libertando-a no fim. Não concluímos que compensa guardar qualquer DataFrame: aqui há reutilização suficiente para pagar a materialização.

4.2 O1: janela ou agregação seguida de junção

Uma janela coloca as viagens do mesmo grupo juntas e calcula as estatísticas nesse conjunto. A alternativa agrega primeiro por zona e hora e distribui a pequena tabela de médias/desvios por broadcast. A hipótese foi reduzir o volume que passa por ordenação e shuffle. A mediana de O1 foi 12,68 s com janela e 5,20 s com groupBy; na pipeline completa, 83,298 e 76,861 s, respetivamente.

As métricas globais ajudam a explicar o resultado: o shuffle escrito mediano foi 955,4 MiB com janela, contra 129,8 MiB com groupBy; o spill em disco passou de cerca de 660,8 MiB para zero. As classificações e os resultados comparados coincidiram. Mantivemos groupBy, distinguindo o ganho do bloco O1, cerca de 59%, do ganho global de 7,7%.

Tabela 2: Comparações globais. Cada linha mantém as restantes opções; as reduções não se somam. Tempos em segundos.

Alternativa → escolha	Antes	Escolha	Redução
Sem cache → cache	101,27	76,86	24,1%
O1 janela → groupBy	83,30	76,86	7,7%
Zonas merge → broadcast	95,89	76,86	19,8%
AQE desligado → ligado	333,60	76,86	77,0%

4.3 Junções com a tabela de zonas

A tabela de zonas tem apenas 265 linhas. A hipótese foi que copiá-la para os executors evitaria o shuffle das viagens que uma junção sort-merge exige. Forçámos a alternativa com `hint("merge")` nas junções às zonas, mantendo tudo o resto. Os planos iniciais mostram `SortMergeJoin`, ordenações e `Exchange` nessa variante; com broadcast mostram `BroadcastHashJoin`.

A mediana da pipeline foi 95,893 s com merge e 76,861 s com broadcast, menos 19,8%. O shuffle escrito mediano foi 4437,4 contra 129,8 MiB, e o spill em disco 3307,5 contra zero. São métricas da pipeline inteira, não apenas do join. A Figura 1 também mostra o limite da escolha: broadcast não elimina o shuffle necessário para as agregações.

4.4 AQE e número inicial de partições

Com AQE desligado, a mediana subiu para 333,595 s e as tarefas para 8428, contra 5469 na referência com AQE. Em M2, a mediana da agregação/escrita foi 144,41 s, e a primeira corrida escreveu 684 ficheiros Parquet, contra 18 com AQE. Agendar tarefas e criar ficheiros tem custos fixos, mesmo com pouco conteúdo por saída. A hipótese de excesso de pequenas tarefas e ficheiros é compatível com estes resultados, sem medir o peso de cada custo separadamente. Numa inspeção separada, o plano final de M2 apresenta `AQEShuffleRead coalesced` com AQE e não o apresenta sem AQE. Isto apoia a explicação, mas não permite atribuir todo o ganho a um único mecanismo adaptativo. Mantivemos AQE ligado, incluindo as opções de coalescência, skew join e leitor local de shuffle.

Testámos ainda 12 e 24 partições iniciais contra as 200 da referência. Com seis slots, correspondem a duas e quatro partições por slot. As medianas foram 75,708, 76,223 e 76,861 s. A vantagem observada de 12 foi só 1,5%, com intervalos de tempos sobrepostos e uma referência de 200 medida noutro momento. Na consulta M2 inspecionada, AQE reduziu os resultados a 2, 2 e 3 partições, respetivamente. Mantivemos 200: não demonstrámos uma vantagem estável de reduzir esse valor. São partições iniciais de shuffle, não uma divisão manual dos ficheiros de entrada com `repartition`.

4.5 Complemento local: a mesma pipeline sem Docker

Repetimos as alternativas num segundo PC sem Docker (`local[*]`, Windows 11, 16 threads, 8 GB para o driver), com 10% dos dados, uma ou duas corridas por configuração e a mesma referência. Os tempos absolutos não são comparáveis com os do Docker; comparamos só a direção dos efeitos (Tabela 3). Cache e AQE ajudaram nos dois ambientes; o broadcast valeu menos em local, onde o shuffle

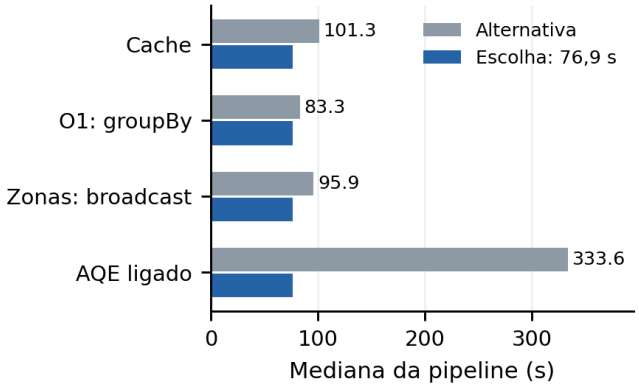


Figura 2: Tempos globais das alternativas. A mesma referência com cache é reutilizada nas comparações, não medida de novo por linha.

não sai do processo, e no O1 janela e groupBy empataram (13,1 e 13,7 s).

A maior diferença foi nas partições (Figura 3): em local, 200 → 32 reduziu a pipeline de 163 para 59 s, com 8 a 32 partições equivalentes e 64 já pior, e de 211 para 109 s com todos os dados. A nossa hipótese, não verificada, é um custo fixo maior por tarefa e por ficheiro em Windows (por exemplo, as chamadas ao `winutils`), que a coalescência do AQE não compensa. A melhor escolha para esta opção depende, assim, do ambiente de execução.

Tabela 3: Redução do tempo da pipeline com cada escolha, nos dois ambientes.

Alternativa → escolha	Local	Docker
Sem cache → cache	17%	24,1%
Zonas merge → broadcast	8%	19,8%
AQE desligado → ligado	61%	77,0%
O1 janela → groupBy	n.s.	7,7%
200 partições → 32 / 12	64%	1,5%

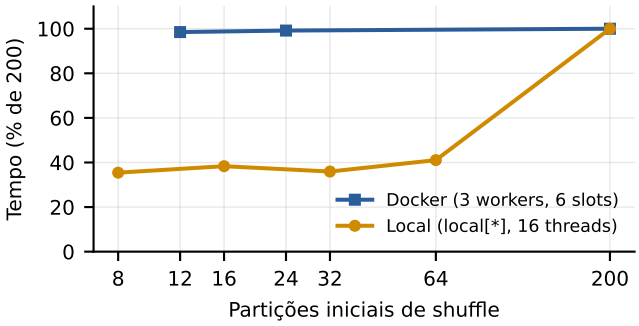


Figura 3: Tempo da pipeline em função das partições iniciais de shuffle, em percentagem do tempo com 200 em cada ambiente. Os tempos absolutos não são comparáveis entre ambientes.

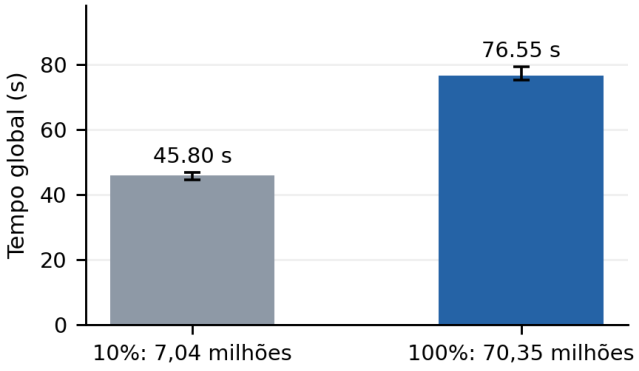


Figura 4: Pipeline com 10% e 100%, três workers. Barras de erro: mínimo e máximo das três corridas, não intervalos de confiança.

5 ANÁLISE DE ESCALABILIDADE

Usámos a configuração escolhida: cache, broadcast das zonas, O1 por groupBy, AQE e 200 partições iniciais de shuffle. As experiências de escala têm aplicações novas e três repetições próprias. A referência de três workers passou a ter mediana 76,546 s; não substituímos os 76,861 s das experiências anteriores.

5.1 Amostra de 10% e conjunto completo

A amostra usa seed 42 depois de unir os 24 ficheiros. Conserva 7 947 434 viagens antes da limpeza e 7 036 182 depois. Os tempos foram 46,842, 44,523 e 45,802 s, com mediana 45,802 s. Com todos os dados, a mediana foi 76,546 s (Figura 4). Cerca de dez vezes mais viagens válidas exigiram 1,67 vezes o tempo: crescimento sublinear observado.

A amostra continua a percorrer os mesmos ficheiros; não representa ler só 10% dos bytes físicos. Há custos fixos de planeamento, agendamento e escrita, e M3 mantém as 6312 linhas da grelha zona/mês. Isto ajuda a interpretar o resultado, sem demonstrar uma lei geral de escala. Como complemento, um, dois e três anos tiveram medianas 45,932, 76,546 e 101,328 s. O caso de três anos acrescenta 2022; não substitui a comparação de amostragem e muda o histórico de M3.

5.2 Número de workers

Repetimos os dados completos com 1, 2, 3 e 6 workers, em três rondas nessa ordem. Calculámos $S_N = T_1/T_N$ e $E_N = S_N/N$; a referência tem um worker de dois slots, não execução sequencial num core. A Tabela 4 e a Figura 5 mostram os resultados. De dois para três workers, o speedup foi 1,27 para um aumento de recursos de 1,5 vezes, ou cerca de 84,4% de eficiência relativa a dois workers.

Três workers deram a menor mediana. Seis tiveram 77,653 s e tempos sobrepostos aos de três, sem vantagem clara. Mais workers partilham o mesmo disco e processador, acrescentam coordenação e aumentam também a memória total anunciada ao Spark. A experiência não isola o efeito do número de cores nem reproduz uma escala em máquinas independentes. Mantivemos três workers como escolha prática para este PC, sem afirmar que é o ótimo em qualquer cluster.

Tabela 4: Escala com dados fixos; mediana de três corridas.

Workers	Slots	Tempo (s)	S_N	E_N
1	2	137,38	1,00	100,0%
2	4	96,85	1,42	70,9%
3	6	76,55	1,79	59,8%
6	12	77,65	1,77	29,5%

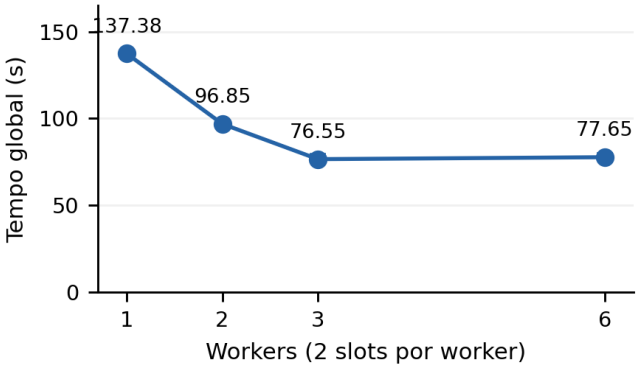


Figura 5: Tempo com 1, 2, 3 e 6 workers no mesmo PC. Barras de erro: mínimo e máximo de três corridas.

6 DISCUSSÃO

O maior contraste observado foi AQE ligado/desligado. A escrita de M2 mostrou que o número de pequenas tarefas e ficheiros pode pesar mais do que esperávamos. A cache também compensou, porque os mesmos dados limpos alimentam várias operações. Em sentido contrário, reduzir as partições iniciais ou duplicar os workers de três para seis não trouxe uma melhoria suficientemente clara. Os resultados mostram por que precisamos de medir tempo, shuffle, spill e tarefas em conjunto: por exemplo, com cache houve mais tarefas do que na baseline, mas menos tempo global.

Há limitações. Só fizemos três repetições, a ordem não foi aleatória e não controlámos a cache de ficheiros do sistema operativo nem toda a atividade do PC. Nas partições, alternámos 12/24, mas reutilizámos as corridas anteriores de 200. Não medimos distribuições de duração de tarefas para diagnosticar skew, não há estudo de UDF e não testámos outras ordens de múltiplos joins. Os planos separados ajudam a interpretar os operadores, mas não provam qual foi o peso de cada operador nas escritas medidas.

Com mais tempo, repetiríamos as alternativas próximas em ordem alternada, recolheríamos métricas por tarefa e testaríamos noutro computador ou cluster com nós independentes. Também fixaríamos as dependências e a imagem Docker por versão imutável: o README regista as versões observadas, mas um build futuro pode mudar. A conclusão atual é limitada aos dados, recursos e opções testados; preservar os resultados foi condição para aceitar cada escolha.

REFERÊNCIAS

[1] Hervé Paulino. 2026. *ComPar 26/27 Project Assignment 1: Large-Scale Analytics with Spark*. Enunciado da unidade curricular.
[2] NYC Taxi and Limousine Commission. *TLC Trip Record Data*. Dados Yellow Taxi de 2023 e 2024 e Taxi Zone Lookup Table. https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page. URLs mensais e hashes em `download_manifest.csv` no repositório.
[3] Computação Paralela. 2026. *Lab 03: Spark Profiling and Optimization*. Notebooks e helper `spark_profiler.py` fornecidos nos materiais da unidade curricular.

AGRADECIMENTOS E UTILIZAÇÃO DE IA

Agradecemos os materiais das aulas e das Labs, que serviram de base à implementação e ao estudo de desempenho, incluindo o profiler da Lab 3.

Usámos o ChatGPT/Codex e Claude para esclarecer e rever comandos menos familiares, apoiar correções numéricas e criar verificações de resultados. Exemplos: conversões com `try_cast`, união com `unionByName`, limites de `rangeBetween`, comparações com `exceptAll` e médias em decimal. O apoio incluiu também preparar e executar experiências, interpretar métricas, organizar notebooks e preparar o rascunho deste relatório. A base de trabalho partiu dos materiais das aulas e das Labs e foi desenvolvida por ambos, com o apoio de IA descrito acima.

Os pedidos incluíram, em resumo: investigar diferenças de arredondamento a 10% e 100%; medir o efeito da cache e interpretar as métricas e os planos de execução do Spark. Não desenvolvemos um agente próprio. As regras de trabalho foram preservar dados e resultados, separar validação de medição e justificar as conclusões com evidência.

CONTRIBUIÇÕES INDIVIDUAIS

Frederico Mestre (77940) — 50%. Preparação da baseline, desenvolvimento e testes da pipeline, estudo das alternativas de otimização e preparação de texto sobre a pipeline e as otimizações.

Tiago Pinho (77970) — 50%. Preparação e validação no Docker, experiências de desempenho e escalabilidade, organização das evidências e integração do relatório.

Ambos trabalharam sobre a pipeline completa. A escolha do ambiente final, a discussão dos resultados e as conclusões são trabalho coletivo. A divisão de 50% para cada elemento reflete a contribuição global, não a atribuição exclusiva de módulos a uma pessoa.